

# Aplicação de Redes Neurais Artificiais na Precificação de Opções de Compra: uma abordagem baseada no modelo Black-Scholes

O avanço da inteligência artificial tem proporcionado soluções cada vez mais sofisticadas para problemas clássicos do mercado financeiro. Um dos campos mais desafiadores, a **precificação de derivativos**, tem se beneficiado significativamente dessas inovações. Neste estudo, apresento uma aplicação de **Redes Neurais Artificiais (RNA)** na tarefa de **precificar opções de compra (calls)**, com base no consagrado modelo **Black-Scholes**.

## Objetivo e estrutura do modelo

O objetivo central do projeto foi avaliar a capacidade preditiva de uma RNA ao aprender os padrões do modelo Black-Scholes e reproduzir os preços teóricos de opções de compra.

As variáveis de entrada utilizadas foram:

- **Moneyness** (relação entre o preço de exercício e o preço à vista)
- **Tempo para o vencimento**
- **Volatilidade**
- **Taxa livre de risco**

A variável prevista foi o **preço da opção (call)**.

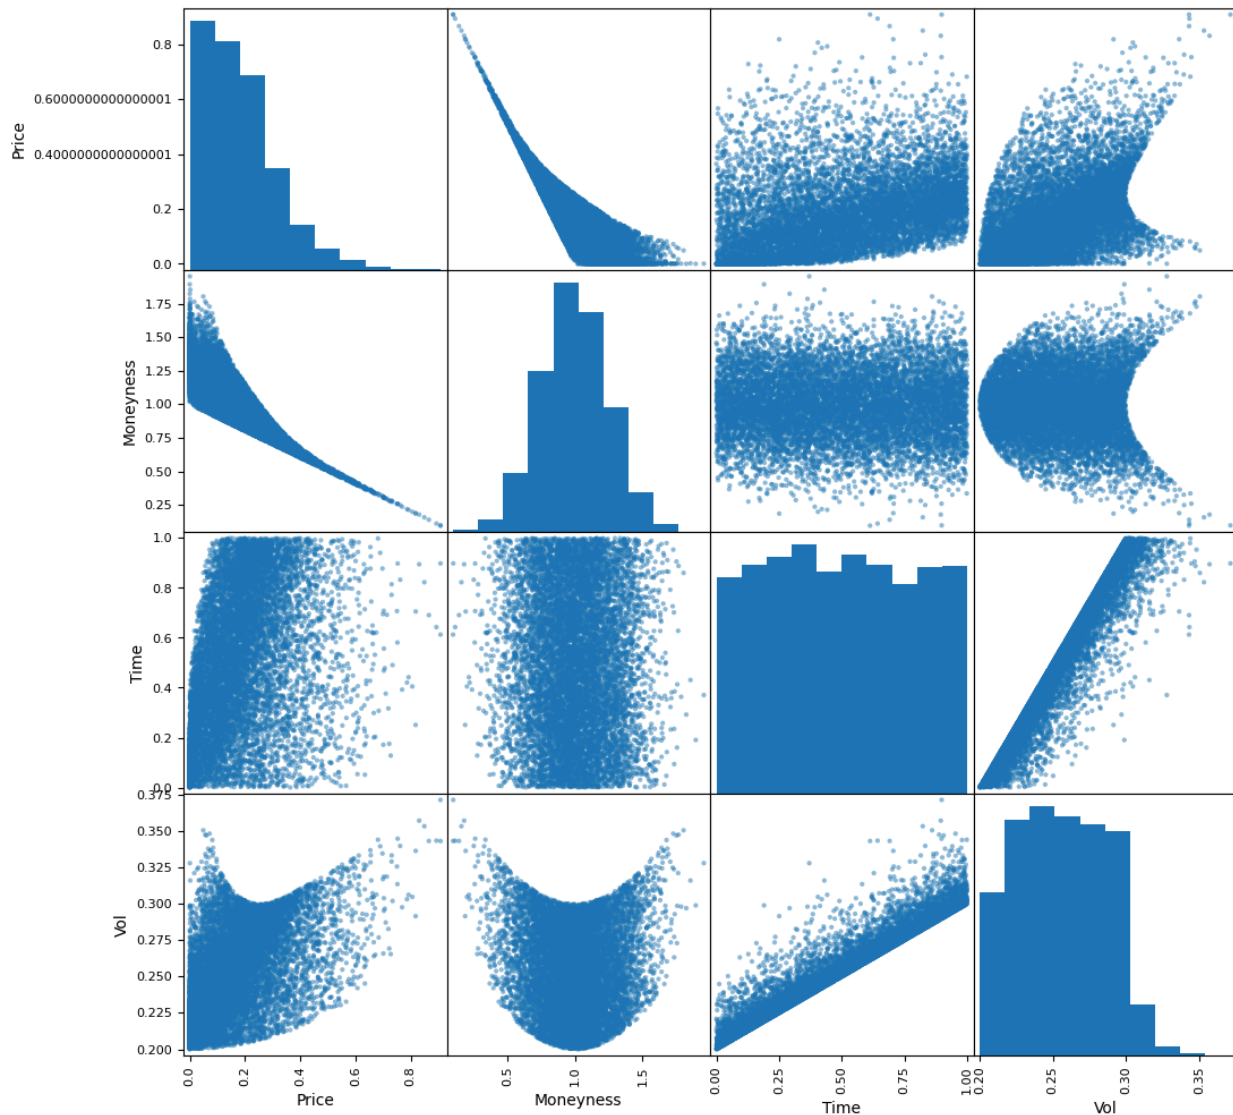
## Análise exploratória das variáveis

A análise exploratória foi conduzida por meio de um gráfico *pairplot*, que permitiu observar as relações entre as variáveis do conjunto de dados:

- **Moneyness vs. Preço da opção:** identifica-se que, à medida que o moneyness diminui (isto é, quanto mais a opção está *in the money*), há um aumento significativo no preço da opção.
- **Tempo vs. Preço da opção:** opções com maior tempo até o vencimento tendem a possuir preços mais elevados, refletindo o valor temporal.
- **Volatilidade vs. Preço da opção:** confirma-se que o aumento da volatilidade está associado a um aumento no preço da opção, dado o maior potencial de valorização do

ativo subjacente.


Além disso, observou-se que a variável mais influente na precificação foi o **moneyness**, seguida da **volatilidade** e do **tempo para vencimento**. As relações apresentadas são notadamente **não lineares**, o que justifica a escolha de modelos capazes de capturar tais complexidades.



## Comparação de modelos e desempenho preditivo

Diversos algoritmos de regressão foram comparados por meio de validação cruzada K-Fold. O desempenho foi avaliado utilizando o erro médio absoluto (MAE), conforme o gráfico boxplot e a tabela abaixo:

Algorithm Comparison: Kfold results



É possível concluir que **modelos lineares não apresentaram bom desempenho**, ao passo que **modelos não lineares, como árvores de decisão e redes neurais, obtiveram erros significativamente menores**.

```
LR: 0.000340 (0.000024) 0.000339 0.000382
LASSO: 0.018664 (0.001075) 0.018654 0.018198
EN: 0.018664 (0.001075) 0.018654 0.018198
KNN: 0.000016 (0.000005) 0.000009 0.000009
CART: 0.000010 (0.000000) 0.000000 0.000009
SVR: 0.004127 (0.000152) 0.004109 0.004084
MLP: 0.000044 (0.000018) 0.000062 0.000070
ABR: 0.000664 (0.000053) 0.000660 0.000697
GBR: 0.000020 (0.000002) 0.000015 0.000018
RFR: 0.000002 (0.000000) 0.000000 0.000002
ETR: 0.000001 (0.000000) 0.000000 0.000000
```

## Arquitetura da Rede Neural Artificial (MLP)

Optou-se por uma RNA com **três camadas ocultas**, contendo respectivamente **20, 30 e 20 neurônios**. A escolha dessa configuração foi resultado de testes sucessivos que indicaram:

- Um número maior de nós na camada intermediária melhora o ajuste no conjunto de treinamento.
- Um número menor de nós favorece a capacidade de generalização do modelo em novos dados.

O desempenho final da RNA foi altamente satisfatório, apresentando um **Root Mean Squared Error (RMSE)** de aproximadamente **4.5891e-05**, o que representa uma taxa de erro **inferior a 1%**. Esse resultado reforça a robustez do modelo em replicar os preços teóricos do Black-Scholes com elevado grau de precisão.

```
Best: -0.000027 using {'hidden_layer_sizes': (20, 30, 20)}
-0.000712 (0.000509) with: {'hidden_layer_sizes': (20,)}
-0.000168 (0.000106) with: {'hidden_layer_sizes': (50,)}
-0.000052 (0.000045) with: {'hidden_layer_sizes': (20, 20)}
-0.000027 (0.000013) with: {'hidden_layer_sizes': (20, 30, 20)}
```

```
# Acuracia estimada do teste
```

```
predictions = model_tuned.predict(X_test)
print(mean_squared_error(Y_test, predictions))
```

```
4.589178712289728e-05
```

O estudo demonstrou que **as Redes Neurais Artificiais são capazes de aprender e reproduzir com alta fidelidade a lógica do modelo de Black-Scholes**, apresentando desempenho superior aos métodos tradicionais de regressão linear.

Além disso, a RNA mostrou-se:

- Altamente eficiente em termos de tempo de execução;
- Flexível para ajustes e expansão;
- Promissora para aplicações práticas no mercado financeiro, inclusive com dados reais.

Dessa forma, conclui-se que **as Redes Neurais representam uma alternativa viável e precisa para a precificação de opções no contexto moderno**, onde a velocidade e a adaptabilidade dos modelos são fatores críticos.

Um desafio futuro, será usar dados reais e criar um pipeline onde os dados são coletados diretamente do mercado.

Referência.

Blueprints de Aprendizado de Máquina e Ciência de Dados para Finanças.